

Detection of Settlements without Electricity

1st Miguel Hortelano Busto
Màster en teledetecció
Universitat de València
València, Spain
mihorbus@alumni.uv.es

2nd Bertran Mollà Bononad
Màster en teledetecció
Universitat de València
València, Spain
bermobo@alumni.uv.es

3rd José Luis García Soria
Màster en teledetecció
Universitat de València
València, Spain
jogarso2@alumni.uv.es

Abstract—L'objectiu d'aquest article és desenvolupar un algorisme supervisat que classifiqui en les classes assentament humà sense electricitat, sense assentaments humans i sense electricitat, assentaments humans amb electricitat, sense assentaments i amb electricitat. S'han provat dos aproximacions al problema i s'han desenvolupat una màscara de núvols i s'ha quantificat l'S/N ràtio de les imatges.

Index Terms—ground classification, S-N ratio, supervised classification, ACP analysis

I. INTRODUCCIÓ

L'observació de la terra des de satèl·lit ens pot donar accés a informació de cobertura de sol. Per aquest motiu és una ferramenta important a l'hora de fer classificacions de l'ús del sol, especialment en situacions on és difícil accedir a les zones d'estudi, com per exemple llocs afectats per desastres naturals o remots i amb xarxes de transport poc desenvolupades. Davant la dificultat d'arribar a estes zones es podria acudir a la classificació d'imatges remotes per a distingir edificis sense accés a l'electricitat potencialment afectats o simplement més difícils de detectar que aquells que en tenen accés. Totes les dades i el plantejament del problema corresponen al concurs de IEEE GRSS Data fusion Contest 2021.

En aquest article a partir del següent conjunt de dades: LC08-Landsat8 11 bandes 3d, L2A-Sentinel-2 12 bandes 4d, Sentinel-1 VV y VH 4d, VIIRS 1b, en 60 retalls de 800x800 píxels, s'han implementat diversos classificadors supervisats amb un Ground Truth de 16x16 píxels que consta de les següents 4 classes: assentament humà sense electricitat, sense assentaments humans i sense electricitat, assentaments humans amb electricitat, sense assentaments i amb electricitat. Molta bibliografia empra per a la classificació d'àrees construïdes l'anàlisi de sèries temporals que amb prou èxit [1] [2] [3] [4], en este cas les dades proporcionades no abasteixen prou temps com per a aprofitar este tipus d'estudi.

Per a aconseguir-ho s'han hagut de desenvolupar les següents ferramentes prèvies a les classificacions:

- Programa de càrrega de dades iteratiu sobre els distints retalls.
- Funció de reescalat que posa veritat terreny i imatges en la mateixa resolució.
- Màscara de núvols a partir de Sentinel-2 i Landsat.

- Funció d'aproximació de la ràtio senyal-soroll.
- Funció d'obtenció de la separabilitat de classes amb la distància de Jeffreis-Matusita.

Una vegada es tenen les imatges lliures de núvols, en resolució de 800x800 píxels s'aplica una mediana com a tractament del soroll existent en les imatges. Després, s'han provat principalment dos aproximacions a la classificació:

- Tractament basat en selecció de bandes.
- Ús de les components principal de les imatges per a la classificació.

Sobre aquestes dos aproximacions al problema s'han comparat els següents classificadors supervisats: k-NN, model d'anàlisi discriminant quadràtic i arbre de decissió, tots ells a partir de les funcions disponibles en la *Statistics and Machine Learning Toolbox* de Matlab.

II. METODOLOGIA

A. Anàlisi de la ràtio senyal-soroll

Primerament s'ha obtingut la ràtio senyal-soroll de les dades a analitzar, fent en el procés uns *boxplots* sobre la senyal-soroll de cada satèl·lit, integrada per a tots les quadrícules i tots els dies:

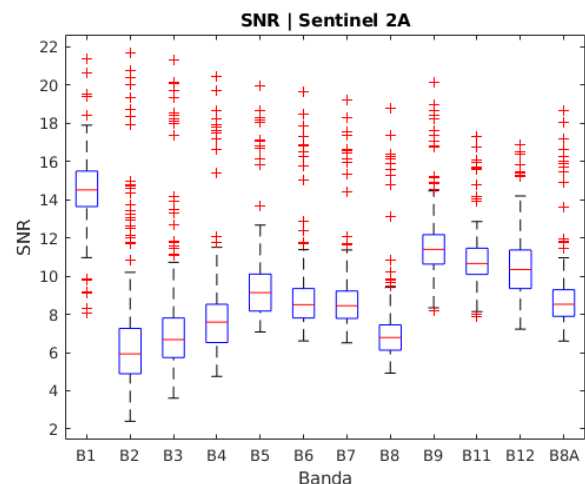


Figura 1. Ràtio senyal-soroll de les dades Sentinel 2A.

Com es pot veure a les figures 1 i 2, tenim una S/N molt variada; això ens suscita un parell de comentaris. Per una

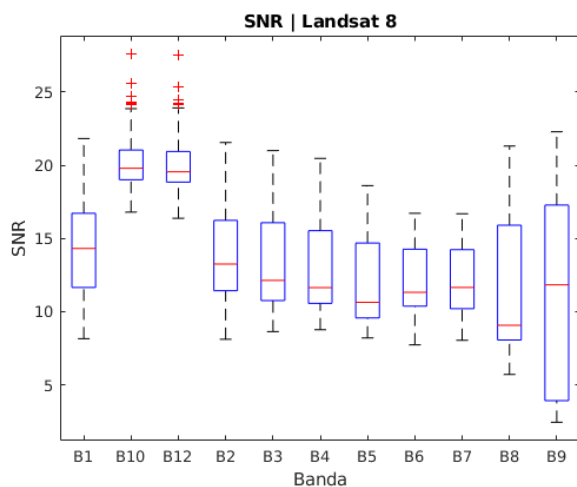


Figura 2. Ràtio senyal-soroll de les dades Landsat 8 TM.

banda, observem que per a Sentinel 2A les bandes presenten un gran nombre d'*outliers*, anant en alguns casos des dels quasi 8 dB fins els 20 dB; a més a més, en general la majoria de bandes tenen la seua mediana per baix d'una S/N acceptable de 10 dB. Per altre costat, les dades Landsat 8 són d'una major qualitat; açò és, la majoria de les imatges es troben per sobre dels 10 dB.

Conseqüentment, per mantindre les dades de Sentinel 2A i no quedar-nos sense informació en eixes dates, en comptes de seleccionar les bandes amb una S/N major a 10 dB, s'ha optat per dur a terme un filtre de mediana espacial sobre les diferents bandes.

B. Mascarat de núvols, ombres i masses d'aigua

Les imatges proporcionades tant de Landsat8 com Sentinel2 tenen píxels afectats per la presència de núvols i boires. Eliminar-les es vital per a poder discriminar píxels vàlids de sòl. A més, moltes de les imatges problemàtiques presenten grups de núvols ben definits que projecten ombra sobre el terreny. Les bandes al SWIR son clau per a la detecció de núvols, mentre que una combinació de bandes del visible i infraroig s'han emprat per a detectar zones d'ombra amb reflectivitat quasi nul·la. Landsat 8 compta amb una banda específica d'absorció en aigua (B9 1360–1390 nm) que destaca zones nuboses [6], encara que es troba sorollosa i inútil per algunes de les imatges, per altra part a Sentinel2 la banda 11 (1610 nm) [7].

Després de provar alguns classificadors, el mètode que equilibrava temps de processat amb efectivitat de detecció ha sigut l'establiment de llindars. Els histogrames típics de les imatges al SWIR mostraven 3 regions clares: un primer pic amb valors molt baixos on es troben els píxels d'ombra, un segon pic dominant on es distribueixen les dades de sol i una llarga cua amb valors alts que correspon als núvols. Per a evitar la detecció com a núvol de píxels de sol amb alta reflectivitat aïllats s'aplica un filtre de mediana a la màscara. Com el gros

del treball no és la detecció de les masses nuvoloses ni tenim imatges de les zones nuvoloses (més enllà del que podem veure al visible), no s'han fet processos de validació reals, però la confirmació visual és satisfactòria.

C. Classificadors: components principals

La primera aproximació que es va provar per a discernir les classes de interès va consistir en afegir a la funció de lectura de dades un anàlisi de components principals de les bandes de cada satèl·lit sostrets els núvols.

L'objectiu amb aquest procediment és doble. D'una banda un anàlisi de les components principals agrupa la informació de les distintes bandes en característiques principals, possiblement algunes d'aquestes característiques han de coincidir en les classes d'interès. D'altra banda reduint les imatges a unes poques CPs reduïm la quantitat d'informació i el cost computacional de produir els models de classificació.

Finalment i donades les característiques de les imatges es van extraure: 1 CP de la imatge DNB de VIIRS (poca variància entre dates); 3 CPs de Landsat8 i Sentinel-2; 2 CPs de Sentinel-1 (1 per polarització). Sobre aquestes CPs es van aplicar un classificador k-NN i un anàlisi discriminant quadràtic.

D. Selecció de bandes

Enlloc de transformar les dades en busca de noves dimensionalitats del problema, altra solució és la selecció de les bandes que millor separen les classes a cercar.

Amb aquest objectiu es van plantejar dues vies. En primer lloc, es va cercar en la bibliografia [1] existent bandes o índexs útils per a separar les classes d'interès. Els índexs usats són: NDBI per a resaltar les construccions; NDVI i NDMIR per a resaltar la vegetació; MNDWI per a discriminar possibles masses d'aigua; NDGB i NDRB per a ajudar a la separació dels assentaments respecte de sol nu, rocòs.

En segon lloc es van computar les distintes combinacions possibles de bandes dels distintes satèl·lits i es va calcular la separació espectral de les classes mitjançant la distància de Jeffries-Matusita.

En aquest procediment sempre s'ha inclòs una mediana temporal de les imatges VIIRS, estes són imatges nocturnes del visible i infraroig proper. Aquestes imatges destaquen notablement les zones il·luminades de nit, bé siga per les pròpies llars o el enllumenat públic. Fent la mediana obtenim aquesta informació en una sola banda que ens permet tractar amb els outliers. Respecte a Sentinel 1 s'ha optat per incloure sols una mediana temporal de la polarització VV, ja que com s'indicava en [1] no pareix haver una millora respecte a l'ús conjunt amb VH.

1) *Distància de Jeffries-Matussita*: La distància de Jeffries-Matussita es una mesura de la separabilitat entre dues classes a partir d'un conjunt de bandes acotada entre 0 i 2, si és inferior a 1.8 es considera no separable. Per aquest motiu es va decidir implementar un codi que la calculara entre totes les classes, els resultats que es mostren pertanyen a la separabilitat entre la classe 1 i la resta i la mitjana, donat que aquesta és la classe d'interès.

Es va calcular la distància per als següents conjunts de bandes: totes les possibles combinacions de 6 bandes de Sentinel2; el conjunt d'índexs trobat a la referència [1]; les components principals descrites anteriorment. Les distàncies obtingudes es presenten en la taula de la figura 3.

Separabilitat	Mitja	Classe 2	Classe 3	Classe 4
CP	0.15	0.06	0.24	0.14
Índexos	0.75	0.24	1.32	0.70
Sentinel 2	1.23	0.34	1.89	1.65

Figura 3. Taula de la separabilitat mitja i de la classe 1 respecte de la resta amb les CP, els índexs seleccionats i les combinacions de Sentinel 2.

Trobem que tant les CP com els índexos es troben lluny de presentar una bona separabilitat. Tot i açò com es veurà en l'apartat de resultats els model donen un millor resultat amb els índexs, cosa coherent amb el fet que la seua distància es major que la de les CP, tant de mitja com a les classes per separat.

Pel que fa al conjunt de 6 bandes de Sentinel 2, la hipòtesi era que, donat que LC08 i Sentinel2 són redundants espectralment en algunes bandes, una combinació de 6 bandes d'un d'ells funcionaria millor que els dos en conjunt donada la limitació en la quantitat de bandes a usar. Com es pot veure presenta una separabilitat millor que els índexs, però l'obtenció de les distàncies de totes les possibles combinacions va requerir un temps de computació massa elevat. Per aquest motiu no es té un model a partir del set bandes que dona estes distàncies, en concret: B1,B2,B3,B8,B9,B12.

III. RESULTATS

El mètode de validació escollit ha sigut de tipus creuat. Açò és, es tenien originalment un conjunt de 60 retalls de 8x8km metres dels quals es disposa d'una veritat terreny en una resolució de 16x16 píxels. S'han fet 5 iteracions a les quals s'escolleixen aleatòriament 12 retalls per a validació i 48 per a entrenament, d'aquesta forma s'han entrenat i validat 5 models a partir de les mateixes dades però amb distints conjunts d'entrenament i validació. El motiu d'aquesta decisió és que per a validar es pren la moda de les prediccions de cada píxel de veritat terreny, fet que redueix notablement les dades.

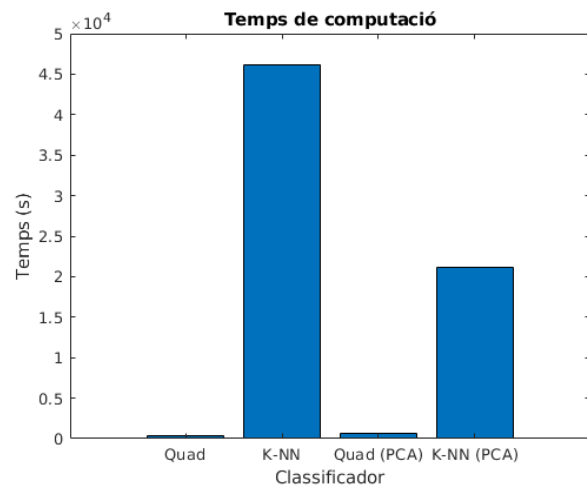


Figura 4. Comparativa de temps d'entrenament de les 5 iteracions de cada mètode. No es contabilitza la lectura d'imatges per ser un temps comú a tots i menyspreable front a l'entrenament, en les PCA s'inclou el temps d'anàlisis de components principals.

Com es pot veure els temps d'entrenament són notablement variables. El classificador quadràtic de màxima versemblança presenta en ambdós casos un temps d'entrenament breu. D'altra banda el k-NN entrenat amb els índexs duplica el temps d'entrenament del basat en components principals. No s'ha inclòs el temps d'entrenament de *tree* donat que sols es te una iteració que va requerir d'unes 13 hores, fent-lo no viable amb les nostres capacitats.

Model	OA (%) / Kappa	PP Classe 1 (%)	PU Classe 1 (%)
K-NN	87.65 / 0.77	84.51	88.49
Quad	53.71 / 0.22	89.90	49.06
K-NN (PCA)	62.03 / 0.26	54.31	58.07
Quad (PCA)	54.62 / 0.24	85.54	49.47
Arbre*	88.57 / 0.77	89.74	80.69

Figura 5. Paràmetres estadístics dels classificadors. (*) Els paràmetres de l'arbre corresponent a una sola iteració.

A priori, sembla que si volem discernir la classe 1 no hi ha una opció preferible, a excepció del k-NN entrenat amb components principals que mostra uns resultats notablement pitjors a la resta de models. Ara bé, si comparem PP i PU (veure figura 5), i a més analitzem les corbes ROC (veure figura 6) les diferències entre els models són evidents:

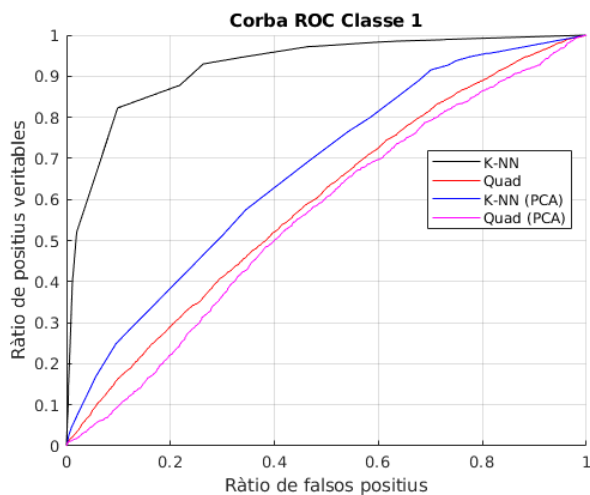


Figura 6. Corbes ROC dels diferents models per a la classe 1.




Figura 7. Matriu de confusió del classificador k-NN sobre les bandes seleccionades.

Si bé podríem pensar que per predir la classe 1, el classificador de màxima versemblança quadràtic entrenat amb índexs és millor que el k-NN ja que és diversos ordres de magnitud més ràpid i mostra una elevada PP a la classe 1, observant les corbes ROC a la figura 6 és evident que tant per al cas de les PCAs com per al propi classificador quadràtic, es té un elevat nombre de falsos positius confontent especialment les classes 1 i 2.

Com a últim resultat i exemple del classificador es mostra en la figura 8 la veritat terreny del retall 14 i la classe 1, núvols i resta de classes obtinguts amb el classificador k-NN amb els índexs.




Figura 8. Dreta veritat terreny retall 14: roig classe1, blau classe2, groc classe 3 i lila classe 4; Esquerra classificació obtinguda, sols es mostra la classe 1 i els núvols.

IV. CONCLUSIONS

Al llarg d'aquest treball s'han provat distintes metodologies per a dur a terme la tasca de classificar els píxels existents en un conjunt de retalls. També s'han hagut de desenvolupar tasques d'avaluació de la bondat de les imatges tant a nivell de nuvolositat com de la ràtio de senyal-soroll que presentaven.

Els millors resultat pertanyen al k-NN amb 12 veïns i distància de Chebychev aplicat sobre el conjunt d'índexs de l'article [1]. La seua precisió sobre la classe objectiu del 84% i factor Kappa 0.78, millorant l'ús de les components principals i el classificador quadràtic de màxima versemblança. Cal destacar que l'ús d'un arbre de decisió sembla donar un resultat amb més encerts, però amb cost computacional entre un i dos ordres de magnitud major, no assolible amb els nostres mitjans.

REFERÈNCIES

- [1] Mattia Marconcini, Annekatrin Metz-Marconcini, Soner Üreyen, Daniela Palacios-Lopez, Wiebke Hanke, Felix Bachofer, Julian Zeidler, Thomas Esch, Noel Gorelick, Ashwin Kakarla, Marc Paganini & Emanuele Strano, "Outlining where humans live, the World Settlement Footprint 2015," ScientificData (2020) 7:242.
- [2] Xiaotian Yan, Li Jia, Massimo Menenti, Jie Zhou, Qiting Chen, Filtering the NPP-VIIRS Nighttime Light Data or Improved Detection of Settlements in Africa, remote sensing (2019) 11:3002.
- [3] B.P. Salmon, J.C Olivier, W.Kleynhans, K.J Wessels, F. vanden Bergh, K.C. Steenkamp, The use of a Multilayer Perceptron for detecting new human settlements forma time series of Modis images, International Journal of Applied Earth Observation and Geoinformation (2011) 13:873.
- [4] Ilari Määttä, Christian Lessmann, Human Lights, remote sensing (2019) 11:2194.
- [5] Floyd M. Henderson, Zong-Guo Xin, SAR Applications in Human Settlement Detection, Population Estimation and Urban Land Use Pattern Analysis: A Status Report, IEE Transactions on Geoscience and remote sensing (1997) 35.
- [6] Charlie Loyd, Landsat 8 bands, <https://landsat.gsfc.nasa.gov/landsat-8/landsat-8-bands>, published on June 14, 2013.
- [7] US department of interior, USGS EROS Archive Sentinel 2, <https://www.usgs.gov/centers/eros/science/usgs-eros-archive-sentinel-2>, retrieved 10/03/2021.